被计数的我们：数据女性主义与公共数据实践

> 唯理寒假工作坊 2027 · 「身份与社会」方向 · 课程设计草案（brainstorm 阶段，持续迭代）

- 时长：5 天（3 天压缩版见文末）
- 人数：建议 12–16 人，最多 20 人，4–5 组
- 主线：数据与身份 —— 谁被计数，谁被看见
- 理论框架：data justice、feminist data science、algorithmic fairness、computational social science、sociotechnical systems、data journalism、public-interest technology
- 议题方向（讲师有研究积累）：医疗健康 / 医疗资源、性别、平台算法
- 最终成果：每组一件 —— 交互式 dashboard 或数据新闻短篇，部署为网页
- 技术路径：不教代码；学员用 DeepSeek API + coding agent 调用公共数据 API，完成一个可公开的成品

讲师声明（草稿，可用于开课第一页）

> 本课程讲师的专业背景为［数据科学 / 量化研究，具体背景待填］，在医疗健康、性别与平台算法方面有研究经验，并非法律、政治学或计算机安全领域的从业者。课程中涉及的法律案例（如荷兰 SyRI 判决、Bartz v. Anthropic 和解、《个人信息保护法》条文）和政策讨论，仅用于说明数据如何在制度中被生产和使用，内容依据公开的判决、报告和新闻报道整理，不构成法律意见，也不代表对任何政策或政治立场的评价。涉及技术的部分（如差分隐私、模型审计）以帮助理解为目的，做了简化。

配套材料（均在本目录）

文件	内容	用在哪天
methods-five-steps.md	研究五步法、UMass 案例示范、研究设计卡	Day 1 起每天
teasers.md	五个开场引子（升学漏斗、平台隐私、再识别、Anthropic 与 Swartz、AI 产业的劳动）及核实结果	Day 1–5
lab-survey.md	参考实验室与 BU 讲座系列：完整研究、可用数据库、仅有方向	选题与案例
cancelled-systems-cases.md	12 个被取消的政府算法系统拆解	Day 4
missing-data-detective-samples.md	"缺失数据侦探"样本与参考答案（初稿，形式待重新设计）	Day 3

---

0. 设计原则

1. 理论—方法—本地问题三层结构：理论告诉我们关注什么不平等或权力关系；方法论告诉我们怎样形成可信的证据；项目把二者转化为可以动手调查的问题。

2. 连接理论与真实数据，而不是"用数据泛泛说明一个现象"。每个结论都要回答：我们能说什么，不能说什么。
3. 第一天不记录个人数据，先学会消化铺天盖地的数据，再各自收集感兴趣的数据集。
4. 验证贯穿每天下午：既验证数据，也验证 AI（agent 可能编造数据或静默丢行）。
5. 讲师提前准备：GitHub 上 2–3 个示范项目 + 模板仓库，学员把时间花在提问与解释上，而不是环境和找数据上。

1. 与 2026 课表的关系

2026 课表（A–E 组共 27 门）没有一门数据或量化课程，但学员熟悉的议题与本课直接相通：

- 分类与身份建构：A01（人性边界）、A04（身体如何被归类与消费）
- 性别与女性声音：A08、D04、A03
- 日常治理与等待：B01（街头官僚、法律意识）
- 质性方法与民族志：B01、B04

本课补上的是：把这些直觉变成可以检验的证据的能力。

2. 每日安排

2.1 一周总览

天	主题	开场引子	上午核心理论	上午核心案例	下午方法练习	当天项目里程碑
1	在数据洪流里读懂一个数字	"一半人上职高？"——升学漏斗	Data Feminism 第 6 章；Gitelman；Datasheets for Datasets；研究五步法	用 UMass 薪酬性别差距走一遍五步法；讲师示范项目	数据类型导览；配置 coding agent；第一次调用 API	选定数据源，提交"数据说明书"和研究设计卡第 1–3 步
2	分类即权力：数据如何给人分配身份、又如何认出你	"几个特征就能认出你"——再识别	Bowker & Star；Cheney-Lippold；Crenshaw；Data Feminism 第 4 章；Nissenbaum 情境完整性	创作领域代表性（基准人群抹去了谁）；姓名推断性别；人口普查重建攻击	分类审计；k-匿名小游戏	确定研究问题，完成分类审计表
3	系统性低代表与缺失数据	"心脏病发作时，胸痛是“典型”症状吗？"	Data Feminism 第 1–2 章；Invisible Women；Library of Missing Datasets；Waldman 论性别数据；探索性序列设计	三种"看不见"：女性被排除在临床研究外、跨性别者没有类别、女性心脏病被误读	缺失数据侦探；代表性比值与基准敏感性分析	核心指标或"缺失地图"；"不能声称什么"清单

天	主题	开场引子	上午核心理论	上午核心案例	下午方法练习	当天项目里程碑
4	从数据到决定：概率、期望值与算法	"导不出的聊天记录"——平台决策树	基础比率、自然频数、期望值、阈值；Nissenbaum 情境完整性；Eubanks；Benjamin；Noble；Data Justice；公平定义不可兼得	12 个被取消的算法系统；Obermeyer；警察拦停阈值检验；YouTube 推荐审计	龙卷风图；阈值游戏；审计权练习；LLM 配对审计	作品初稿 + "决策卡"
5	讲出可信的故事 → 结课展	"同样是大量下载文本"——Anthropic 与 Aaron Swartz	The Markup "show your work"；Data Humanism；不确定性可视化	AI 产业的劳动（圆桌）；反驱逐地图项目（形式参照）	互评、修改、部署	结课展

2.2 每天的时间结构

时段	时间	内容
上午	09:30–09:50	引子：一个和学员生活相关的数据问题（详见 teasers.md）
	09:50–10:50	理论共读与讲授
	10:50–11:00	休息
	11:00–11:50	案例研讨 / 跨组圆桌
	11:50–12:00	下午任务说明
午休	12:00–13:30	
下午	13:30–14:15	全班方法练习
	14:15–15:45	分组制作（中间休息 10 分钟）
	15:45–16:15	验证环节：既验证数据，也验证 AI
	16:15–16:30	进度分享与同伴反馈（每组 3 分钟）
	16:30–17:00	Office Hour

贯穿全周的三条线

1. 证据线：每个结论都要对照第 3 节的「不能直接声称什么」证据表。
2. 验证线：每天下午固定 30 分钟验证，检查的对象每天递进：数据是否拉对 → 类别和缺失 → 基准与敏感性 → 假设与重复实验 → 互评。
3. 伦理线：只用公开数据；不对他人做身份推断或定位；涉及个人经验的环节一律自愿。

Day 1｜在数据洪流里读懂一个数字

> 目标：学会在铺天盖地的数字面前先问五个问题，再去找自己感兴趣的数据。

09:30 引子：一半人上职高？（teasers.md 引子一）

- 给出一句常见说法："初中毕业后一半人上普高、一半人上职高"。
- 学员拿到 2024 年教育统计公报的几个数字（初中毕业生、普高招生、中职招生、高考报名、本科招生），自己检验这句话。
- 讨论：换成不同的分母，"考上本科的比例"从约 55% 变到约 37%，甚至更低。同一个比例，取决于你选哪个分母。

09:50 理论

- D'Ignazio & Klein, *Data Feminism*（2020）第 6 章 "The Numbers Don't Speak for Themselves"
- Gitelman (ed.), *"Raw Data" Is an Oxymoron*（2013）导论：数据从来不是"原始"的
- Gebru et al., "Datasheets for Datasets"（2021）
- 产出：「数字体检表」五问——来源、定义、分母、比较对象、不确定性

11:00 研究五步法（methods-five-steps.md）

1. 把观点改写成可以被证伪的命题（"外卖平台越来越压榨骑手"→"在观察时段内，平台促销期间骑手每小时净收入是否更高？"）
2. 定义概念与变量：分子、分母、单位、时间窗口、适用人群
3. 事先写好数据来源与采样规则，避免只收集支持自己观点的案例
4. 先看分布、缺失、异常值，再选分析方法；差异不等于因果
5. 主动找反例，做稳健性检查；结论分三层："数据直接显示了什么""我们推测了什么""现有数据还无法证明什么"

- 完整示范：用 UMass 薪酬性别差距（CBS Boston × BU Justice Media co-Lab，lab-survey A10）走一遍五步；这也是一件学员几天内就能复刻尺度的数据新闻成品
- 讲师的 GitHub 示范项目：成品长什么样、代码和数据怎么组织

13:30 方法

- 数据类型导览：表格、记录级、地理、收藏与文化记录、文本、模型生成数据、时间序列，各自会遮蔽什么（第 4 节数据目录）
- 数据采集伦理与法律提醒（15 分钟，第 6 节）：先讲规则，再动手——官方 API 优先；禁止抓取的不抓；不登录、不绕过反爬；他人信息最小化、去标识、只发布汇总
- 配置 coding agent，第一次成功调用公共 API（环境已在课前线上会配置好）

14:15 分组制作

- 每人从数据目录中挑一个感兴趣的数据集，按 Datasheets 格式写一页「数据说明书」
- 按兴趣分组：医疗健康、性别、平台算法
- 每组填写研究设计卡第 1–3 步：可证伪的命题、变量定义、数据来源与采样规则（看数据之前写好）

15:45 验证：把 agent 拉到的数据和源网页逐条对照（行数、字段、抽查 5 条记录）；记录 agent 有没有编造或丢掉数据。

里程碑：每组选定数据源，成功拉取数据，提交数据说明书和研究设计卡第 1–3 步。之后每天下午更新一次设计卡。

Day 2 | 分类即权力：数据如何给人分配身份，又如何认出你

> 目标：理解类别是被设计出来的；同时理解，正是这些类别的组合能把一个人认出来。

09:30 引子：几个特征就能认出你（teasers.md 引子三）

- 邮编 + 性别 + 生日能唯一识别多少美国人？Sweeney（2000）估计 87%，Golle（2006）复核得到 61%–63%。
- 当场用合成数据演示：每加一个特征，"唯一的人"的比例怎么上升。

09:50 理论

- Bowker & Star, *Sorting Things Out*（1999）
- Cheney-Lippold, *We Are Data*（2017）：算法给出的"可测量类型"
- Crenshaw（1989）：交叉性
- *Data Feminism* 第 4 章 "What Gets Counted Counts"
- Nissenbaum：情境完整性。信息在一个语境中合理，被重新组合进另一个语境就可能造成伤害

11:00 案例

- 基准人群本身抹去了谁：创作领域代表性研究指出，美国社区调查没有非二元、跨性别等类别（lab-survey A2）
- 用姓名推断性别，准确率 97.5%：剩下 2.5% 是谁？非二元性别的人在哪里？（lab-survey A3）
- "去掉名字"不等于匿名：美国人口普查局用 2010 年公开汇总表精确重建了约 9,700 万条个人记录，促成 2020 年改用差分隐私；HIPAA 的去标识化规则就是一张"哪些特征危险"的清单
- 自媒体时代的准标识符：平台强制显示的 IP 属地；大模型能从帖子推断位置和收入、从照片推断地点
- 跨组圆桌：最容易被认出来的，为什么往往本来就是少数群体？

13:30 方法

- k-匿名小游戏（合成数据）：逐步加入"城市 → 区 → 学校 → 年级 → 生日月份"
- 可选自我审计（自愿，不分享）：私下列出自己一条公开帖子里的准标识符，只上交类别清单

14:15 分组制作：对本组数据集做「分类审计」——类别如何定义、谁被合并、谁落进"其他"、谁根本没有类别；用 agent 做分组统计和交叉表。

15:45 验证：缺失值审计（随机缺失还是有模式？）；交叉分类后每个格子的样本量是否过小。格子太小既是统计问题，也是再识别风险。

里程碑：每组确定研究问题，完成分类审计表。

伦理提示：任何练习都不对他人的照片或帖子做定位或身份推断。

Day 3｜系统性低代表与缺失数据（Data Feminism 深入）

> 核心问题：一个群体在数据里"看不见"，是因为没被计数、被计错了类别，还是被看见了却被误读？三种情况的研究方法完全不同。

09:30 引子：心脏病发作时，胸痛是"典型"症状吗？

- 先让学员凭直觉回答：女性心脏病发作的症状和男性一样吗？
- 再给出 VIRGO 研究的数据（Lichtman et al., *Circulation*, 2018，美国 103 家医院、18–55 岁心肌梗死住院患者，🔎 据新闻报道）：
  - 胸痛、胸闷在女性和男性中都是主要症状（87% vs 89.5%），但女性报告的其他症状更多
  - 入院前就医时，53% 的女性被告知"不是心脏问题"，男性为 37%
- 讨论：问题出在症状不同，还是出在别人怎么解读症状？

09:50 理论

- *Data Feminism* 第 1–2 章：检视权力、挑战权力。第 1 章以 Serena Williams 产后险些丧命开篇，讨论美国黑人女性孕产妇死亡率与孕产妇死亡数据的薄弱；书中引用美国疾控中心官员的话："我们选择测量什么，表明了我们在健康上重视什么。"
- Criado Perez, *Invisible Women*（2019）：性别数据鸿沟
- Onuoha, *The Library of Missing Datasets*（2016）：数据为什么会缺席
- Waldman, "Gender Data in the Automated Administrative State"（*Columbia Law Review*）：是法律（法定要求、官方表格、跨部门数据共享、自动化系统采购），而不只是技术设计，造成了跨性别、非二元人群在政府数据中被抹去（🔎 据摘要）

11:00 案例：三种"看不见"

类型	案例	关键事实
没被计数	女性被排除在临床研究之外	1977 年美国 FDA 指引禁止大多数"有生育可能"的女性参加临床研究，直到 1993 年才撤销，并由《NIH 振兴法》写入法律（🔎 womenshealth.gov）
	子宫内膜异位症的诊断延迟	一项 2024 年的综述发现平均延迟约 6.6 年，各国差异很大（🔎）。注意：没有研究直接证明这与 1977 年的排除政策有因果关系
	孕产妇死亡数据薄弱	*Data Feminism* 第 1 章；ProPublica 与 NPR 的"Lost Mothers"调查
被计错了类别	跨性别和非二元人群	美国社区调查（ACS）没有性别认同问题；美国国家科学院 2022 年报告建议采用"出生时性别 + 当前性别认同"的两步问法（🔎）；Williams Institute 2022 年估计美国 13 岁以上约 160 万人（0.6%）认同为跨性别，之后有更新的估计，引用前需核对最新数字（🔎）
	人数太少，被并入"其他"或不公布	小样本格子既有统计问题，也有再识别风险（接 Day 2）
	表格怎么设计	Waldman, "Opening the Gender Box"（*Law & Social Inquiry*, 2024）：通过公共记录申请和对设计表格的公务员的访谈，发现表格设计主要受"惯性"驱动；问得太细可能加强监控，问得太粗则造成抹除（🔎 据摘要）

类型	案例	关键事实
被看见，却被误读	女性心脏病被误诊	英国利兹大学对约 56 万名心肌梗死患者的研究（2016）：女性 STEMI 患者初诊错误的概率比男性高 59%，NSTEMI 高 41%，合计约 50%（"50%"来自未发表的补充分析，🔎）
	症状被归因于压力	Chiaramonte 等的情景实验：同样的冠心病症状，加上"压力"描述后，女性获得冠心病诊断的比例为 15%，男性为 56%；不加压力描述时没有观察到偏差（🔎 会议报告）
	"非典型症状"的说法本身	Maserejian 等（*J Womens Health*, 2009）：部分医生把"女性症状不典型"当作泛化规则，反而增加了诊断不确定性（🔎）
对照	Gender Shades	人脸识别对深肤色女性错误率最高 34.7%，对浅肤色男性最高 0.8%
对照	Data Against Feminicide	官方数据缺席时，活动者如何生产"反数据"（lab-survey A9）

圆桌讨论：女性心脏病被误诊，是数据缺失还是刻板印象？

两者都有，而且互相强化：

1. 数据缺失：所谓"典型症状"是从以男性为主的研究中总结出来的，女性的症状因此被标为"非典型"。默认是男性，女性成了例外。
2. 刻板印象：当症状和压力、焦虑同时出现时，女性的症状更容易被归因于心理原因。
3. 需要修正的说法：现有证据显示的是女性症状更常被归因于压力或焦虑，而不是专门被"诊断为抑郁症"；而且女性和男性一样，最常见的症状仍是胸痛。课上的说法应该依据证据精确表述。

方法论专题：怎样研究缺失的数据（11:40–12:00）

1. 先问"为什么缺"
   - Onuoha 的分类：收集成本高于收益、有人不希望它被收集、它抗拒被量化、没有人有动力去收集
   - 统计学的分类（Rubin, 1976；Little & Rubin）：完全随机缺失、随机缺失、非随机缺失。插补等统计修补方法通常假设缺失是随机的；而当缺失本身和被研究的问题有关时（例如表格里根本没有某个类别），统计方法补不回来。
2. 先质性、后量化：这是一种标准的混合方法设计，叫探索性序列设计（exploratory sequential design，Creswell & Plano Clark）：
   - 先用访谈、文献、参与式观察了解这个领域有什么已有知识和假设
   - 再据此决定要测量什么变量、设计什么问卷
   - 适用于"现成的测量工具和变量还不存在或不适用于这个人群"的情况，而这正是缺失数据研究的常态
   - 例子：Waldman 先通过公共记录和访谈了解表格怎么被设计出来；Data Against Feminicide 先与活动者合作，才设计标注体系
3. 测量"缺席"本身：缺失审计（谁不在分母里、哪些字段为空）、分类体系分析（有哪些类别、没有哪些）
4. 检查测量是否有效：你测的东西真的是你想测的东西吗？（Jacobs & Wallach, 2021，见 methods-five-steps.md 第二步）
5. 反数据与参与式研究：当官方数据缺席，和受影响的社群一起生产数据

13:30 方法：缺失数据侦探（45 分钟，全班；样本与参考答案初稿见 missing-data-detective-samples.md，练习形式待讲师重新设计）

- 每组拿到一份公开问卷或数据字典（例如美国人口普查问卷、DHS 女性问卷、死亡证明书的妊娠勾选框、中国第七次人口普查表）
- 任务：
  1. 列出哪些群体或类别不在其中
  2. 判断每一项属于"没被计数""被计错类别"还是"被看见却被误读"
  3. 按探索性序列设计写一个计划：在收集任何数字之前，你需要先问谁、读什么、了解什么？

14:15 分组制作

- 在数据存在的地方，计算代表性比值（样本中的占比 ÷ 基准人群中的占比）。例如用 ClinicalTrials.gov 计算某类疾病临床试验的女性参与-患病比（PPR，Scott et al., 2018）
- 在数据缺失的地方，把缺失本身做成发现：画出"谁不在数据里"
- 更新研究设计卡第 4、5 步

15:45 验证：换三个不同的基准人群，结论是否翻转；用第二个独立数据源交叉核对；检查缺失是否随机。

16:15 中期检查（延长到 25 分钟）：每组 3 分钟讲"初步发现 + 我们能不能这么说"，其他组对照证据表提问。

里程碑：核心指标或"缺失地图"、第一张图、一份"我们不能声称什么"清单。

课堂注意：讨论跨性别和非二元议题时，不要求任何学员披露自己的身份；讨论只针对数据和制度设计。

Day 4 | 从数据到决定：概率、期望值与算法

> 逻辑：每一个决定（个人的、医生的、算法的）都是"概率 × 后果"的权衡。算法决策系统只是把这套权衡自动化、规模化了。先学会自己做决定，再审视机器替人做的决定。

09:30 引子：导不出的聊天记录（teasers.md 引子二）

- 现场让学员试着把一段微信聊天导出成能读的文件，会发现做不到；对照 WhatsApp 的 .txt 导出和账户信息报告。
- 引出决策树：免费使用、付费、离开，三个选项各值多少？隐私损失的概率根本算不出来，所以用"盈亏平衡点"思考。

09:50 理论

- 决策科学基础：基础比率、期望值、敏感性分析、决策阈值（Hammond, Keeney & Raiffa, *Smart Choices*, 1999）；用"自然频数"理解筛查阳性的真实含义（Gigerenzer et al., 2007）
- 期望值的正义问题：平均来看最优的决定，代价由谁承担？
- 平台、隐私与情境：
  - Nissenbaum, "Privacy as Contextual Integrity"（*Washington Law Review*, 2004）：同一项个人信息，在一个场景中被收集合乎预期，换到另一个场景就可能越界
  - Data Justice：数据系统在解决谁的问题，又让谁承担代价

    - Benjamin：表面中立的技术分类如何复制既有的社会等级
    - 核心问题：同一项个人信息在不同场景中被收集或使用，是否符合用户对该场景的合理预期？不同用户看到的价格、推荐或默认选项，是否存在可观察的差异？
- Eubanks, *Automating Inequality*（2018）；Benjamin, *Race After Technology*（2019）；Noble, *Algorithms of Oppression*（2018）；Dencik et al., *Data Justice*（2022）
- 代理指标：Obermeyer et al.（2019），以"医疗花费"代理"健康需求"
- 公平定义不可兼得（Kleinberg et al., 2016；Chouldechova, 2017）：同一个阈值用在基础比率不同的群体上，会产生不同的错误率
- 方法范例：
    - 警察拦停的"夜幕检验"与"阈值检验"（Pierson et al., 2020，lab-survey A6）
    - YouTube 推荐链审计（lab-survey A7）
- 大模型里的偏见：从词向量到"显性无偏、隐性有偏"（lab-survey F 节）
    - 起点：Bolukbasi 等（2016）在 Google News 词向量里发现"男人之于程序员，就像女人之于家庭主妇"；Caliskan 等（*Science*, 2017）发现词向量复现了人类内隐联想测验中的偏见
    - 今天的处理办法：数据过滤、训练后对齐（人类反馈强化学习等）、偏见基准测试（WinoBias、BBQ、中文 CBBQ 等）、系统提示词
    - 但问题没有消失：对齐后的模型通过显性偏见测试，在二选一决策中仍表现出刻板印象（Bai et al., *PNAS*, 2025）；人类反馈训练让模型表面说法更正面，却没有消除对方言使用者的隐性偏见（Hofmann et al., *Nature*, 2024）；名字不同、资历相同的简历，排序结果不同（Bloomberg, 2024）

11:00 案例：12 个被取消的算法系统（cancelled-systems-cases.md）

- 分组拆解（30 分钟）：每组领 2–3 个案例，按"为什么引入 → 怎么运作 → 出了什么问题 → 有什么证据 → 怎么被取消"填表；重点回答"引入时有什么证据表明它会有效？谁批准的？"
- 对照讨论（20 分钟）：
    - PRECOBS（事先安排独立评估）vs MiDAS（"以破纪录的速度"上线，事后查出 4 万起错误指控）
    - 用平均值替代真实波动，怎样系统性冤枉了收入不稳定的人（MiDAS、Robo-debt）

13:30 方法（全班，45 分钟）

- 龙卷风图：用引子里的平台决策树，看哪个参数一变结论就翻转
- 阈值游戏：在一组风险评分上拖动阈值，观察不同群体的假阳性和假阴性；用 HART"约 2 次谨慎错误对 1 次危险错误"的设定讨论：被高估风险的人失去了什么？
- 审计权练习：假设你被某个系统标记了，列出要质疑结果需要知道什么（用了我的哪些数据、变量、权重、我的分数、阈值、错误率、向谁申诉），对照 12 个案例，看哪些系统能回答几项

14:15 分组制作

- 完成作品初稿
- 平台算法组可选：
    - 大模型显性 / 隐性偏见对照审计（用 DeepSeek API，借鉴 Bai et al. 2025 与 Hofmann et al. 2024 的设计）：
        - 显性测试：直接问模型对某个群体的看法（预期回答得体）

        - 隐性测试：只改姓名或性别，其他条件固定，让模型写故事并统计角色分配、给资历相同的简历排序、在两名候选人之间二选一
        - 比较两组结果；每个条件重复多次、固定 temperature；先写假设再跑
        - 边界：只用虚构的姓名和简历，不输入任何真实个人信息；结论只针对所测的模型、提示词和时间点
    - App 隐私与界面审计：比较不同 App 的权限请求、隐私政策与默认设置；在不违反平台规则、不伪造身份、不涉及真实交易的前提下，做标准化的界面观察（方法和警示见第 4 节数据目录）
- 每组写一张**「决策卡」**：这份分析能为什么决定提供依据？结论对哪个假设最敏感？谁会承担错误的代价？

15:45 验证：先写假设再算；关键参数取上下限；LLM 实验每个条件重复多次、固定 temperature；区分"观察到的差异"和"能推断的机制"。

里程碑：作品初稿 + 决策卡。

Day 5 | 讲出可信的故事 → 结课展

> 目标：作品不只是"一张好看的图"，而是一件能经得起追问、标明来源和局限的公共作品。

09:30 引子：同样是"大量下载文本"（teasers.md 引子四）

- Aaron Swartz 下载约 480 万篇论文，JSTOR 不愿追究，联邦检察官仍以 13 项重罪起诉；Anthropic 因从盗版网站下载图书达成 15 亿美元民事和解，而购买纸质书扫描训练被认定为合理使用。
- 讨论：法律把什么当作犯罪、把什么当作可以用钱解决的纠纷？训练数据背后是谁的劳动？
- 延伸圆桌：AI 产业的劳动（teasers.md 引子五）——高薪技术岗、低薪标注岗和用户的"数据贡献"，是不是同一个产业的不同劳动市场？工人为替代自己的机器人采集数据意味着什么？
- 收回到学员自己：你的作品用了谁的数据？你是否标明了来源、许可和署名？
- 注意：讲到 Swartz 去世时，平实陈述，不描述细节，不简单归因；课前或课后告知心理支持资源。

09:50 理论

- The Markup 的方法论公开实践（"show your work"）
- Giorgia Lupi, Data Humanism 宣言（2017）
- 不确定性的可视化
- 形式参照：反驱逐地图项目（Anti-Eviction Mapping Project）——量化地图 + 个体叙事 + 公共展示

11:00 跨组互评圆桌

- 每组 5 分钟展示，其他组扮演"挑刺的编辑"，按一张清单提问：
    1. 证据表：有没有说了不能说的话？
    2. 分母和基准：换一个会怎样？
    3. 审计：读者能不能查到你用了什么数据、怎么处理的？
    4. 署名：数据来源和许可写清楚了吗？

13:30 修改与部署（90 分钟）

15:00 布展

15:15–16:45 结课展（开放工作室）。每件作品必须附三个面板：

- 方法与局限：我们知道什么、从哪里知道、还不知道什么
- 决策卡
- 数据来源与署名（附"数据伦理清单"，见第 6.6 节）

16:45 结课：每人写下一个"这周之后我再看到数字时会问的问题"。

3. 「不能直接声称什么」—— 贯穿全课的证据表

研究目标	优先方法	典型产出	不能直接声称什么
描述分布	描述统计、分层统计	分布图、比例、分位数	不能解释成因
比较群体或区域	标准化指标、分组比较、空间分析	差异图、比较表	不能把差异自动归因于身份或地域
检验相关	相关、回归、混杂审查	关联强度、置信区间	相关不等于因果
检查系统是否区别对待	标准化审计、配对比较、重复观察	同条件下的差异	不一定能确定内部机制或意图
研究谁没被记录	缺失审计、分类体系分析、访谈	缺失模式、盲点清单	没有记录不等于不存在

4. 数据目录：讲师策展的数据集 + 实测可用的免费 API

选题方式：各组从讲师提供的目录中选择（策展好的静态数据集，或测试过的免费 API）。目录覆盖不同数据类型，每种类型对应一个"它会遮蔽什么"的教学点。

> 状态：以下全部为候选，尚未实测。中国大陆可访问性必须在国内网络下测试（云端测试只能证明接口可用，不能证明国内可达）。

数据类型	教学点：它会遮蔽什么	候选来源	对应方向
表格 / 统计指标	平均值与总量掩盖组内差异；口径与分母	World Bank API（Gender Data）；WHO GHO OData API；Our World in Data（图表 CSV 下载）；国家统计局年度报告表格	性别、医疗健康
记录级数据	谁进入了记录系统、谁没有；字段如何定义身份	ClinicalTrials.gov API v2（性别、年龄、入组人数）；openFDA API（不良事件报告含性别字段）	医疗健康
地理 / 空间	地图距离 ≠ 真实可达；有标注 ≠ 设施可用	高德开放平台（POI 搜索、公交路径规划，需 key）；阿里云 DataV GeoAtlas 行政区划 GeoJSON；OpenStreetMap Overpass API（如 wheelchair 标签的覆盖率本身就是缺失数据问题）	医疗资源

数据类型	教学点：它会遮蔽什么	候选来源	对应方向
收藏 / 文化记录	默认类别与"未标注"的权力	大都会博物馆 Open Access API；芝加哥艺术博物馆 API；MoMA collection（GitHub CSV，含性别字段）；QSIDE 博物馆艺术家多样性数据（Topaz et al. 2019）	性别
文本	编码者的判断如何进入数据	政策文件 / 公开报告（由 agent 解析）；GDELT 新闻事件数据	性别、平台算法
模型生成数据	模型输出也是一种"被制造的数据"	DeepSeek API（配对提示审计）	平台算法
时间序列	口径变化与断点	上述来源中的历年指标	全部

借鉴参考实验室的项目题目（详见 lab-survey.md）：

- 街名里的性别：以人名命名的街道中女性占多少（迁移自 MIT Data + Feminism Lab 的 Audit the Streets；OpenStreetMap 数据）
- 谁被收藏：博物馆馆藏和创作领域的性别与族裔构成（QSIDE 数据集）
- 薪酬性别差距：公开薪酬数据（借鉴 BU Justice Media co-Lab 的 UMass 报道）
- 红线区与高温：历史红线地图与地表温度（借鉴 BU Justice Media co-Lab）
- 算法伤害案例拆解：Data Harm Record（Cardiff Data Justice Lab）

平台隐私与界面审计（平台算法组可选）

- 理论：Nissenbaum 情境完整性；Data Justice；Benjamin 对表面中立的技术分类的批判
- 可做的项目：比较不同 App 的权限请求、隐私政策与默认设置；分析推荐页面的内容构成；设计标准化的界面观察实验
- 方法：隐私政策内容分析、界面审计、标准化观察、情境比较。比较价格或推荐结果时，须固定时间、商品、账户状态、地区和其他可能影响结果的条件
- 边界：必须在不违反平台规则、不伪造身份、不涉及真实交易的前提下进行；不收集他人的个人数据，不尝试绕过隐私保护
- 关键警示：两个账户看到不同内容，不足以证明平台歧视某个群体；差异可能来自历史行为、库存、地域或其他因素

AI 产业的劳动与数据（平台算法组可选，见 teasers.md 引子五）：招聘平台上数据标注岗与算法工程师岗的合同形式比较；常用 App 隐私政策中"用用户内容训练 AI"条款的位置、篇幅与默认设置；隐私政策的可读性。只分析公开的岗位描述和政策文本

可选题目：注意力经济（"Who Pays for Free?"）作为平台算法组的可选方向，使用行业报告表格 + 标准化观察协议（详见原始大纲中的项目 B / C / D）。

风险：Wikipedia / Wikidata 在中国大陆通常无法直接访问，不纳入目录；GitHub 访问不稳定，需准备国内可用的展示备选。

参考的 data justice 实践：QSIDE Institute（JustFair 联邦量刑数据、博物馆艺术家多样性数据、Data4Justice Accelerator：API 与爬虫采集、清洗、质性文本量化）；MIT Data + Feminism Lab（Data Against

Feminicide）。

5. Coding agent 落地

- DeepSeek 官方提供 Anthropic 兼容接口 `https://api.deepseek.com/anthropic`，可直接接 Claude Code（模型名课前按官方文档核对）
- API key 由组委按组发放并设消费上限，不让未成年学员各自注册充值
- 开课前一周 1 小时线上环境配置会
- 讲师模板仓库：agent 提示词指南、数据抓取脚手架、验证清单、两个成品模板（ECharts 单页 HTML dashboard；数据新闻长文）
- 明确教学点：agent 会编造数据或静默丢行 —— 验证环节也是"监督 AI"的训练

6. 数据采集的伦理与法律提醒

> 以下是课程的操作规则，用于降低风险，不构成法律意见（见开头的讲师声明）。法律条文以官方文本为准；遇到不确定的情况，一律先停下来问讲师。

6.1 为什么要专门讲

- Day 5 的引子四里，Aaron Swartz 被起诉的主要罪名正是"未经授权访问计算机网络"，而不只是"下载"；Anthropic 的责任来自从盗版网站获取图书。怎么拿到数据，本身就可能是法律问题。
- Day 2 讲过，几个公开的细节组合起来就能认出一个人。数据是公开的，不等于可以随意收集、组合和发布。
- Coding agent 写爬虫很快，但它不会主动检查网站条款，也可能忽略访问频率限制。

6.2 采集前的判断流程

```
1. 有没有官方 API 或开放数据集？
   └── 有 → 优先使用，并遵守其使用条款和调用频率限制

2. 没有，打算抓取网页：
   ├── 网站的用户协议或 robots.txt 是否禁止抓取？        → 禁止就不抓
   ├── 是否需要登录、绕过验证码、破解反爬机制？          → 需要就不做
   └── 以上都不涉及 → 限速、标明身份，只抓需要的字段

3. 数据里有没有个人信息？
   ├── 有敏感个人信息或未成年人信息？                    → 不收集
   └── 有一般个人信息 → 按 6.4 处理：最小化、去标识、只发布汇总

4. 发布的作品会不会让人认出具体的人？
   └── 会 → 合并、删除或不发布
```

`拿不准 → 停下来，问讲师`

6.3 法律层面需要知道的几点（中国）

- 《个人信息保护法》
  - 处理个人信息需要合法依据。对于个人自行公开或其他已经合法公开的个人信息，可以"在合理的范围内"处理，但个人明确拒绝的除外；对个人权益有重大影响的，仍应取得个人同意（第 13 条、第 27 条）。
  - 敏感个人信息包括生物识别、宗教信仰、特定身份、医疗健康、金融账户、行踪轨迹等，以及不满十四周岁未成年人的个人信息（第 28 条）。本课程一律不收集。
- 《刑法》：非法获取计算机信息系统数据（第 285 条）、侵犯公民个人信息（第 253 条之一）都是刑事罪名。绕过技术防护措施抓取数据、买卖个人信息，风险极高。
- 平台用户协议：即使不构成犯罪，违反平台协议抓取数据也可能引发民事纠纷。
- 其他国家和地区的法律各不相同。美国 Swartz 案就是依据《计算机欺诈与滥用法》起诉的。

6.4 从公共平台获取他人信息时怎么处理

原则：能不收集就不收集；必须收集的，尽早去标识；发布时只发布汇总。

环节	规则
收集	只收集回答研究问题必需的字段；不收集用户名、头像、照片、联系方式、精确位置；不收集未成年人的内容；不收集敏感个人信息
存储	收集后立即删除或替换可识别字段（例如用编号代替用户名）；数据只存在本组设备上，不上传公共网盘；课程结束后删除原始数据
分析	只报告汇总结果；如果某个类别人数太少，就合并或不报告（本课程规则：任何一格少于 10 人不单独报告）
引用	不在作品中逐字引用普通用户的帖子：逐字引用可以被搜索到原帖，从而认出发帖人。改为转述，或只报告主题和比例
发布	作品中不出现任何可识别的普通个人；GitHub 仓库里不提交原始数据，只提交汇总数据和处理脚本
公众人物与机构	公众人物以公开身份发表的言论、机构发布的公开文件，可以作为分析对象；但仍不收集其私人生活信息

6.5 Coding agent 使用规则

- 模板仓库里的抓取脚手架默认限速并标明访问身份；不允许学员删除这些设置
- 写给 agent 的提示词里必须包含："遵守 robots.txt 和网站用户协议；不要登录、不要绕过验证码；只抓取以下字段：……"
- 任何抓取网页的脚本，在运行前由讲师或助教检查
- 大模型实验（如 DeepSeek 配对审计）不输入任何真实个人信息

6.6 每组提交的"数据伦理清单"

作品发布前，每组回答并提交：

1. 数据来源是什么？使用条款是否允许我们这样使用？
2. 有没有抓取网页？是否检查了用户协议和 robots.txt？
3. 数据里有没有个人信息？我们删掉或替换了哪些字段？
4. 作品中有没有任何人可能被认出来？
5. 原始数据存在哪里？什么时候删除？

这份清单也是作品"数据来源与署名"面板的一部分。

7. 3 天压缩版

Day 1 + Day 2 合并（研究五步法 + 分类审计）；Day 3 + Day 4 合并（缺失数据 + 算法决策，二选一深入）；Day 5 保留。风险：agent 制作时间不足，需更多依赖模板。

8. 待核实 / 待决定

- ▢ 课程名称；是否在课名中出现"数据女性主义"
- ▢ 讲师示范项目（讲师思考中；候选：临床试验女性 PPR、大模型性别偏向审计、博物馆藏品性别结构、阈值游戏交互工具）
- ▢ 在国内网络下逐一实测数据目录中的 API，淘汰不可用的
- ▢ 核对原文数字：Obermeyer et al. 2019；Gender Shades 2018；Scott et al. 2018（Topaz 2019 已核对）
- ▢ 引子一：对照教育部公报原文核对中职、本科招生数字
- ▢ 引子二：在当前版本微信上实测"导出个人数据"的内容
- ▢ 引子四：核对 Bartz v. Anthropic 和解的最终批准日期与作品数量
- ▢ Day 3：核对 VIRGO（Lichtman 2018）、利兹研究（2016）、Chiaramonte 情景实验的原文数字；核对 Williams Institute 最新跨性别人口估计
- ▢ Day 3："缺失数据侦探"样本初稿偏枯燥，讲师重新设计练习形式；保留现有样本备用
- ▢ Day 3：课前重新打开并确认各样本的官方链接，并对照七普方案原文确认样本 3 的提示
- ▢ 引子五：核对特斯拉工人反对 Optimus 数据采集（The Information 原文）、韩国现代工会罢工的报道
- ▢ 模板仓库：抓取脚手架默认限速与身份标识；agent 提示词指南加入数据采集规则；"数据伦理清单"模板
- ▢ 请组委或法律顾问看一遍第 6 节的法律提醒
- ▢ 准备 Day 2 k-匿名小游戏的合成数据集
- ▢ 制作 Day 4 阈值游戏与龙卷风图的交互工具（可兼作示范项目）
- ▢ 制作 Day 4 案例拆解表模板、Day 5 互评清单
- ▢ 与组委确认：Citizen Lab 微信研究等敏感内容是否引用；涉及自杀内容的提示方式
- ▢ 确认哪家博物馆 API 的性别字段"只标注女性"
- ▢ DeepSeek 当前模型名与定价